

Volatilidade Estocástica e Quebras Estruturais

Resumo Metodológico Didático para Pesquisa em Finanças

Baseado em revisão sistemática via Consensus (2026) — Uso interno de pesquisa

Sumário

1	Introdução e Motivação	3
2	Parte 1 — Quebras Estruturais: Conceitos e Métodos	3
2.1	O que é uma quebra estrutural?	3
2.2	Principais métodos de detecção	4
2.3	O Teste de Bai–Perron em detalhe	4
3	Parte 2 — Janelas Temporais e Segmentação	5
3.1	A lógica das três janelas	5
3.2	Como escolher o tamanho da janela “durante” (X)?	5
4	Parte 3 — Critérios de Comparação entre Janelas	6
4.1	O que comparar entre as três janelas?	6
4.1.1	1. Média e variância/volatilidade	6
4.1.2	2. Persistência da volatilidade	6
4.1.3	3. Diagnósticos de modelo por subperíodo	7
4.1.4	4. Testes formais de mudança de volatilidade	7
5	Parte 4 — Modelos de Volatilidade Estocástica (SV)	7
5.1	Estrutura básica do modelo SV	7
5.2	Extensões comuns do modelo SV básico	8
6	Parte 5 — Inferência Bayesiana via MCMC	8
6.1	Por que MCMC para modelos SV?	8
6.2	Principais algoritmos	9
6.3	O pacote <code>stochvol</code> no R	9
7	Parte 6 — Como Comparar os Parâmetros Latentes Entre Janelas	10
7.1	Princípio geral	10
7.2	Ferramentas principais	10
7.2.1	A. Intervalos de credibilidade e sobreposição	10
7.2.2	B. Probabilidade posterior de diferença	10

7.2.3	C. Bayes Factors e DIC	10
7.2.4	D. Métricas derivadas dos parâmetros SV	11
7.3	Tabela-resumo das ferramentas de comparação	11
8	Parte 7 — A Pipeline Completa: Bai–Perron + SV-MCMC	12
8.1	Suporte da literatura para a combinação	12
8.2	Fluxograma metodológico	13
8.3	Lacunas e pontos abertos na literatura	13
9	Parte 8 — Caso IBM: o que a literatura diz	14
9.1	IBM e volatilidade estocástica latente	14
10	Glossário de Termos-Chave	14
11	Perguntas Metodológicas Frequentes	15

1 Introdução e Motivação

Este documento resume o estado da literatura sobre dois temas centrais que se combinam em análises de séries financeiras, especialmente ações como a IBM:

1. **Detecção de quebras estruturais** (com destaque para o teste de Bai–Perron) em séries de retornos ou volatilidade.
2. **Modelagem de volatilidade estocástica (SV) via MCMC**, com inferência dos parâmetros latentes μ , ϕ e σ dentro de janelas de tempo definidas pelas quebras.

Conceito-chave

Por que combinar os dois métodos?

Séries financeiras apresentam mudanças de regime ao longo do tempo. Ignorar quebras estruturais ao estimar modelos de volatilidade produz estimativas de persistência *infladas* e previsões ruins fora da amostra [Rohan and Ramanathan, 2012, Bauwens et al., 2014, Hasanov et al., 2024a]. A abordagem correta é: (i) detectar os pontos de quebra, (ii) segmentar a série em janelas e (iii) reestimar o modelo de volatilidade em cada segmento.

2 Parte 1 — Quebras Estruturais: Conceitos e Métodos

2.1 O que é uma quebra estrutural?

Uma **quebra estrutural** ocorre quando os parâmetros de um modelo estatístico mudam de forma permanente em um determinado ponto do tempo. Em séries financeiras, quebras podem afetar:

- o **nível médio** dos retornos (μ);
- a **variância/volatilidade** (a mais comum em finanças);
- a **persistência** da volatilidade (ϕ , no contexto SV).

A crise financeira de 2008 é um dos exemplos mais citados: índices dos EUA (S&P 500, DJIA, VIX) entram em regimes de maior volatilidade em 2008 [Lombera, 2024, Baiardi et al., 2020], e estudos em 16 países identificam a GFC 2008–2009 como uma das principais origens de quebras estruturais em mercados globais [Ndako, 2025].

2.2 Principais métodos de detecção

Método	Foco principal	Referência-chave
Bai–Perron	Múltiplas quebras em média e/ou variância, mínimos quadrados globais	[Bai and Perron, 2002]
CUSUM / ICSS	Quebras em variância, adaptável a dependência temporal	[Aue and Horvath, 2013]
KW-ICSS	Séries não normais; combina ICSS com teste de Kruskal–Wallis	[?]
PELT	Múltiplas quebras com complexidade computacional linear	[Jia, 2025]
ART em séries intervalares	Múltiplas quebras em preços diários	[?]
Métodos de painel	Quebras comuns em muitas séries com T curto	[Antoch et al., 2019]

Tabela 1: Principais métodos para detecção de quebras em séries financeiras.

Atenção metodológica

Bai–Perron e dados de IBM: Historicamente, métodos para detecção de quebras em variância foram aplicados a dados da IBM em trabalhos clássicos (Inclán & Tiao), citados como exemplo canônico de teste de quebras em volatilidade [Aue and Horvath, 2013]. Não há literatura recente focada *exclusivamente* em IBM, mas os métodos consolidados são diretamente aplicáveis.

2.3 O Teste de Bai–Perron em detalhe

O teste de Bai–Perron [Bai and Perron, 2002] identifica **múltiplos** pontos de quebra em um modelo de regressão linear, minimizando a soma de quadrados dos resíduos globalmente. Seus passos principais são:

1. Especificar o número máximo de quebras e a fração mínima de observações entre duas quebras (parâmetro h).
2. Estimar os pontos de quebra via programação dinâmica.
3. Selecionar o número de quebras por critérios de informação (BIC, LWZ) ou por sequência de testes F (sup F , testes de quebra dupla vs. simples).

Na prática

Para aplicar Bai–Perron à **volatilidade** (e não à média), o procedimento padrão é transformar a série: aplica-se Bai–Perron sobre $\log(r_t^2)$ (log do retorno ao quadrado), pois essa transformação aproxima estacionariedade e lineariza a estrutura de variância, alinhando-se às hipóteses do teste [Andreou and Ghysels, 2002, Chin et al., 2016].

3 Parte 2 — Janelas Temporais e Segmentação

3.1 A lógica das três janelas

Após detectar uma quebra com Bai–Perron, é prática corrente na literatura segmentar a série em **três janelas**:

Janela	Definição	Objetivo
Pré-quebra	Do início até o ponto de quebra	Regime “normal” de referência
Durante	X observações após a quebra	Capturar o pico de volatilidade
Pós-quebra	Do fim de X até o final	Regime após a perturbação

Essa segmentação é amplamente usada em estudos de eventos de volatilidade [Jiang et al., 2023, Chin et al., 2016] e em análises de risco financeiro ao redor de crises [?, ?].

3.2 Como escolher o tamanho da janela “durante” (X)?

Atenção metodológica

Não existe um valor canônico universal para X (como “sempre use 60 dias”). A literatura recomenda escolha baseada em critério estatístico ou de previsão, não apenas arbitrária [Inoue et al., 2016, Pesaran and Timmermann, 1999, Pesaran and Timmermann, 2003].

As principais estratégias são:

1. **Rolling window ótima**: escolher X (o tamanho R da janela) que minimiza o Erro Quadrático Médio de Previsão (MSFE) ou outra função de perda [Inoue et al., 2016, Pesaran and Timmermann, 1999].
2. **Janelas fracionárias**: usar metade ou um quarto do total amostral como referência inicial, testando sensibilidade a alternativas (40, 60, 80 dias) [Hasanov et al., 2024b].

3. **Última quebra como início da janela:** começar do último breakpoint estimado e ir até o final da amostra, ignorando o histórico anterior ao break [Hasanov et al., 2024b, Gaetano, 2018].
4. **Adaptação dinâmica (BAWS):** algoritmos que ajustam X *online* em função de mudanças estruturais detectadas [?].

Pergunta de pesquisa associada

Como defender X em um artigo? Apresente: (a) a escolha primária baseada em critério de previsão ou tamanho amostral, e (b) análise de sensibilidade para $X - \Delta$ e $X + \Delta$, mostrando que os resultados principais não mudam [Inoue et al., 2016].

4 Parte 3 — Critérios de Comparação entre Janelas

4.1 O que comparar entre as três janelas?

A literatura usa principalmente quatro categorias de critérios [Abdennadher and Hallara, 2018, Jiang et al., 2023, Tamakoshi and Hamori, 2014, ?]:

4.1.1 1. Média e variância/volatilidade

- Estimar modelos de retorno e volatilidade em cada regime e comparar o **nível médio de retorno** e os **parâmetros da equação de variância** (GARCH, FIGARCH, SV, etc.).
- Incluir **dummies de quebra** na equação de média e/ou variância e testar se seus coeficientes são estatisticamente significativos [Abdennadher and Hallara, 2018, Jiang et al., 2023, Tamakoshi and Hamori, 2014].

4.1.2 2. Persistência da volatilidade

A persistência mede quão rapidamente um choque de volatilidade se dissipa. Em modelos GARCH, é a soma $\alpha + \beta$; em modelos SV, é o parâmetro ϕ . A literatura mostra que modelos *sem* quebras tendem a **superestimar** a persistência [Abdennadher and Hallara, 2018, Jiang et al., 2023, Tamakoshi and Hamori, 2014].

4.1.3 3. Diagnósticos de modelo por subperíodo

Aspecto	Medida	Referência
Autocorrelação de resíduos	Testes Q de Box–Pierce	[Jiang et al., 2023]
Presença de efeito ARCH	Teste ARCH-LM em cada janela	[Jiang et al., 2023]
Ajuste e previsão	AIC/BIC, VaR, erro de previsão	[Jiang et al., 2023, Kashyap and Kas]

4.1.4 4. Testes formais de mudança de volatilidade

Após identificar a janela de maior volatilidade, pode-se testar formalmente se a variância é *time-varying* versus constante, usando:

- **Bayes factors** via razão de Savage–Dickey entre modelo com parâmetros variantes no tempo (TVP-SV) e modelo com parâmetros constantes [Chan, 2018];
- Testes Wald/Score/LR [Dufour and Valéry, 2009];
- Testes exatos de Monte Carlo [Ahsan and Dufour, 2025].

Na prática

Resumo prático da comparação entre janelas:

- (i) testar se média e parâmetros de volatilidade diferem via dummies/regimes;
- (ii) avaliar mudanças na persistência; (iii) checar diagnósticos (autocorrelação, ARCH, qualidade de previsão) em cada subperíodo; (iv) aplicar testes formais de variância variante no tempo.

5 Parte 4 — Modelos de Volatilidade Estocástica (SV)

5.1 Estrutura básica do modelo SV

O modelo de volatilidade estocástica padrão (univariado) é definido por duas equações:

$$y_t = \exp\left(\frac{h_t}{2}\right) \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, 1) \quad (1)$$

$$h_t = \mu + \phi(h_{t-1} - \mu) + \sigma \eta_t, \quad \eta_t \sim \mathcal{N}(0, 1) \quad (2)$$

onde:

- y_t é o retorno observado no tempo t ;

- $h_t = \log(\sigma_t^2)$ é a **log-volatilidade latente** (variável não observada);
- μ é a **média de longo prazo** da log-volatilidade;
- $\phi \in (-1, 1)$ é o parâmetro de **persistência** (quanto maior $|\phi|$, mais lento o retorno à média);
- $\sigma > 0$ é o **desvio padrão do ruído de volatilidade** (vol-of-vol, i.e., volatilidade da própria volatilidade latente).

Conceito-chave

Por que “latente”?

A volatilidade h_t nunca é observada diretamente. O que observamos são os retornos y_t . Todo o processo de inferência consiste em *recuperar* h_t e os parâmetros (μ, ϕ, σ) a partir de $\{y_t\}_{t=1}^T$. Isso torna o modelo muito mais realista, mas também mais complexo de estimar do que GARCH.

5.2 Extensões comuns do modelo SV básico

- **SV com alavancagem:** correlação entre ε_t e η_t (retornos negativos tendem a aumentar a volatilidade) [Omori et al., 2007].
- **SV de longa memória:** substituição do AR(1) em (2) por um processo ARFIMA ou Fractional Gaussian Noise [?].
- **SV com caudas pesadas:** distribuição Student- t ou estável assimétrica para ε_t [Vankov et al., 2019].
- **Markov-switching SV:** os parâmetros (μ, ϕ, σ) alternam entre regimes segundo uma cadeia de Markov oculta [Ghezal et al., 2024, He and Lin, 2022, Makatjane and Molefe, 2020].
- **SV com medidas realizadas:** h_t é atualizado também por medidas de alta frequência (variância realizada, bipower variation) [Bormetti et al., 2019].

6 Parte 5 — Inferência Bayesiana via MCMC

6.1 Por que MCMC para modelos SV?

A verossimilhança de um modelo SV envolve a integral sobre todos os estados latentes $\{h_t\}$, o que é analiticamente intratável. O MCMC (Markov Chain Monte Carlo) resolve isso *amostrando* conjuntamente de $p(\mu, \phi, \sigma, h_1, \dots, h_T \mid y_1, \dots, y_T)$.

6.2 Principais algoritmos

Algoritmo	Como funciona	Referência
Gibbs Sampler	Amostra cada parâmetro condicionado aos demais (blocos condicionais completos). Eficiente quando as condicionais são fechadas.	[Kastner, 2016]
Metropolis-Hastings	Propõe novos valores e aceita/rejeita com base na razão de probabilidades. Usado quando condicionais não são fechadas.	[Kastner, 2016]
Particle MCMC (PMCMC)	Combina filtros de partículas com MCMC para modelos com verossimilhanças intratáveis.	[Vankov et al., 2019, Shapovalova, 2021]
RMHMC	MCMC Riemanniano com informação de curvatura; mais eficiente em espaços de alta dimensão.	[Shapovalova, 2021]
INLA	Approximação determinística à distribuição posterior; muito mais rápida que MCMC para certos modelos.	[?]
Variational Bayes + SMC	Aproximação variacional combinada com Sequential Monte Carlo; escalável.	[Shapovalova, 2021]

Tabela 2: Principais algoritmos para inferência em modelos SV.

6.3 O pacote `stochvol` no R

O pacote `stochvol` [Kastner, 2016, ?] implementa o modelo SV básico (e extensões) com MCMC eficiente. Retorna:

- Draws posteriores de μ, ϕ, σ ;
- Distribuição posterior dos estados latentes h_t ;
- Diagnósticos de convergência (Effective Sample Size – ESS, trace plots, etc.).

Na prática

Uso prático: ao aplicar `stochvol` a uma série financeira (e.g. retornos da IBM), você obtém amostras da distribuição posterior de (μ, ϕ, σ) . Para *comparar* dois

períodos (pré/durante/pós quebra), estima-se o modelo separadamente em cada janela e comparam-se as distribuições posteriores.

7 Parte 6 — Como Comparar os Parâmetros Latentes Entre Janelas

7.1 Princípio geral

Atenção metodológica

Em modelos SV, μ , ϕ e σ são tratados como **variáveis aleatórias** com distribuições posteriores, não como escalares fixos. Portanto, a comparação entre janelas nunca é feita via diferença simples de estimativas pontuais; ela é feita via **comparação de distribuições posteriores e critérios de evidência bayesiana** [Kastner, 2016, Shapovalova, 2021].

7.2 Ferramentas principais

7.2.1 A. Intervalos de credibilidade e sobreposição

O procedimento mais comum na literatura [?, Shapovalova, 2021, Omori et al., 2007]:

1. Estimar o modelo SV separadamente em cada janela.
2. Calcular as médias posteriores e intervalos de credibilidade de 95% (ou HPD – Highest Posterior Density) para μ_1, ϕ_1, σ_1 (janela pré) e μ_2, ϕ_2, σ_2 (janela durante).
3. **Critério de interpretação:** se os intervalos *não* se sobrepõem, há evidência de mudança meaningful no parâmetro.

7.2.2 B. Probabilidade posterior de diferença

A partir dos draws MCMC de cada janela, calcula-se diretamente:

$$P(\phi_{\text{durante}} > \phi_{\text{pré}} \mid \text{dados}) = \frac{1}{S} \sum_{s=1}^S \mathbf{1}[\phi_{\text{durante}}^{(s)} > \phi_{\text{pré}}^{(s)}]$$

onde S é o número de amostras MCMC [Vankov et al., 2019, Shapovalova, 2021].

7.2.3 C. Bayes Factors e DIC

Para comparar modelos ou especificações entre subamostras [Chan, 2022, Chan and Eisenstat, 2018, ?]:

- **Bayes Factor:** razão das verossimilhanças marginais; $BF_{12} > 10$ indica evidência forte a favor do modelo 1.
- **DIC** (Deviance Information Criterion): análogo bayesiano do AIC; penaliza complexidade efetiva. Menor DIC = melhor ajuste.
- **Log-predictive likelihood:** avalia desempenho preditivo fora da amostra [Chan, 2022, ?].

7.2.4 D. Métricas derivadas dos parâmetros SV

A literatura [Rohan and Ramanathan, 2012] reporta regularmente métricas calculadas a partir de (μ, ϕ, σ) que facilitam a interpretação econômica:

Métrica	Fórmula	Interpretação
Meia-vida do choque	$\frac{\log 0.5}{\log \phi }$	Tempo para choque dissipar 50%
Variância incondicional	$\frac{\sigma^2}{1 - \phi^2}$	Variabilidade de longo prazo de h_t
Persistência efetiva	$ \phi $	Quão perto de unit root

Pergunta de pesquisa associada

E se os modelos por janela forem independentes?

A comparação formal via Bayes Factors entre modelos estimados *independentemente* por janela não é padrão e raramente é implementada na literatura [Kastner, 2016]. A prática dominante é comparar médias e intervalos posteriores. Uma alternativa mais rigorosa é especificar um **modelo hierárquico** que linka as janelas conjuntamente [Shapovalova, 2021].

7.3 Tabela-resumo das ferramentas de comparação

Objetivo	Ferramenta / critério	Referência
Avaliar mudança em μ, ϕ, σ	Médias posteriores + intervalos de credibilidade	[Kastner, 2016, ?, Omori et al., 2007]
Testar direção da mudança	$P(\phi_1 > \phi_2 \mid \text{dados})$ via MCMC	[Vankov et al., 2019]
Ranquear regimes/modelos	Marginal likelihood, Bayes Factor, DIC	[Chan, 2022, Chan and Eisenstat, 2018]
Comparar caminhos latentes	Gráficos de volatilidade suavizada, RMSE vs. “verdadeiro”	[Vankov et al., 2019, ?]

Objetivo	Ferramenta / critério	Referência
Avaliar previsão	Log-predictive likelihoods, scores out-of-sample	[Chan, 2022 , ?]
Testar $\phi \approx 1$	Intervalo de credibilidade de ϕ ; checar se 1 está dentro	[Ahsan and Dufour, 2025 , ?]
Testar variância constante vs. vari- ante	Bayes Factor via razão Savage–Dickey	[Chan, 2018]

Tabela 3: Ferramentas para comparar parâmetros SV entre janelas ou modelos.

8 Parte 7 — A Pipeline Completa: Bai–Perron + SV-MCMC

8.1 Suporte da literatura para a combinação

A combinação de **Bai–Perron** com **MCMC-SV por janelas** é metodologicamente suportada, conforme revisão sistemática de 50 papers [[Abdennadher and Hallara, 2018](#), [Kastner, 2016](#), [Bauwens et al., 2014](#), [Rohan and Ramanathan, 2012](#), [Jiang et al., 2023](#), ?]. Especificamente:

- Bai–Perron em $\log(r_t^2)$: justificado para aproximar estacionariedade [[Andreou and Ghysels, 2002](#), [Chin et al., 2016](#)].
- Segmentação pré/durante/pós: prática padrão em event studies de volatilidade [[Jiang et al., 2023](#), [Chin et al., 2016](#)].
- Modelagem SV via MCMC por segmento: bem estabelecida com `stochvol` [[Kastner, 2016](#), [Rohan and Ramanathan, 2012](#)].
- Métricas derivadas (meia-vida, variância incondicional): outputs padrão de análise de regime [[Rohan and Ramanathan, 2012](#)].
- Testes frequentistas complementares (ARCH-LM, RV/BV, permutação, Levene, KS): robustness checks padrão [[Jiang et al., 2023](#), [Shen et al., 2020](#)].

8.2 Fluxograma metodológico

Passo 1 Calcular $\log(r_t^2)$ (ou $\log(RV_t)$)



Passo 2 Aplicar teste de Bai–Perron para detectar breakpoints



Passo 3 Definir as três janelas (pré, durante, pós)



Passo 4 Estimar modelo SV (via `stochvol`) em cada janela



Passo 5 Comparar (μ, ϕ, σ) via intervalos de credibilidade



Passo 6 Calcular métricas derivadas (meia-vida, var. incondicional)



Passo 7 Robustness checks (ARCH-LM, RV/BV, testes distribucionais)

8.3 Lacunas e pontos abertos na literatura

Atenção metodológica

O que ainda não está resolvido (oportunidades de contribuição):

1. **Testes bayesianos formais entre janelas independentes:** a literatura não tem procedimento consolidado para testar $\phi_{\text{pré}} \neq \phi_{\text{durante}}$ quando os modelos são estimados separadamente [Kastner, 2016].
2. **Aplicações intraday com MCMC-SV:** a maioria dos estudos usa dados diários; aplicações intraday são menos documentadas [Kokoszka et al., 2024].
3. **Esquemas ótimos de janelamento:** o impacto de diferentes definições de X (tamanho da janela “durante”) sobre a caracterização dos regimes permanece em aberto [Inoue et al., 2016].

9 Parte 8 — Caso IBM: o que a literatura diz

9.1 IBM e volatilidade estocástica latente

O trabalho mais próximo do caso IBM encontrado na revisão é [Ahsan and Dufour, 2025], que:

- Usa um framework de **variáveis instrumentais de alta frequência** para inferir um processo de volatilidade latente para a IBM, com dados de 2009–2013.
- Conecta medidas de volatilidade realizada (RV) e volatilidades implícitas de opções da IBM ao processo latente.
- Conclui que a volatilidade diária latente da IBM é **altamente persistente** ($\hat{\phi} \approx 0.9$ – 1.0 , próximo a unit root).
- Mostra que medidas de RV em intervalos de 5 minutos e volatilidades implícitas de calls da IBM são os instrumentos mais informativos; RVs de frequência muito alta inflam os intervalos de confiança por ruído de microestrutura.

Conceito-chave

IBM e quebras na crise de 2008: Embora não haja estudo recente focado exclusivamente em IBM, a crise de 2008 produziu quebras documentadas em praticamente todos os ativos da NYSE, incluindo blue chips como IBM. Ferramentas como CUSUM/ICSS foram historicamente aplicadas à série IBM em trabalhos clássicos de Inclán e Tiao, que serviram como caso de teste padrão para métodos de detecção de quebras em variância [Aue and Horvath, 2013].

10 Glossário de Termos-Chave

Quebra estrutural

Mudança permanente nos parâmetros de um modelo ao longo do tempo.

$\log(r_t^2)$ Log do retorno ao quadrado; proxy para log-volatilidade; série sobre a qual Bai–Perron é tipicamente aplicado.

μ (SV) Média de longo prazo da log-volatilidade latente h_t .

ϕ (SV) Persistência da log-volatilidade; controla a velocidade de reversão à média. $|\phi| \rightarrow 1$ implica volatilidade altamente persistente (quase unit root).

σ (SV) Desvio padrão do ruído da equação de transição de h_t (vol-of-vol).

h_t Log-volatilidade latente no tempo t ; variável não observável.

MCMC	Markov Chain Monte Carlo; família de algoritmos para amostrar de distribuições posteriores de alta dimensão.
Credible interval	Intervalo bayesiano de 95% para um parâmetro; análogo ao intervalo de confiança frequentista, mas interpretado como probabilidade real de o parâmetro estar no intervalo dado os dados.
Bayes Factor	Razão de verossimilhanças marginais entre dois modelos; mede evidência relativa entre eles.
DIC	Deviance Information Criterion; critério de seleção de modelo bayesiano que penaliza complexidade efetiva.
HPD	Highest Posterior Density interval; região de menor comprimento que contém 95% da massa posterior.
Meia-vida	$\log(0.5)/\log(\phi)$; número de períodos para um choque se reduzir à metade.
Variância incondicional (SV)	$\sigma^2/(1 - \phi^2)$; variabilidade de longo prazo de h_t .
ARCH-LM	Teste de Lagrange Multiplier para efeitos ARCH; verifica se há autocorrelação nos resíduos ao quadrado.
RV	Variância Realizada; estimador não-paramétrico da variância construído a partir de retornos intraday.
BV	Bipower Variation; variante de RV robusta a saltos.

11 Perguntas Metodológicas Frequentes

1. Posso aplicar Bai–Perron direto nos retornos ou preciso transformar?

Para detectar quebras em *volatilidade*, aplique Bai–Perron em $\log(r_t^2)$ ou em $\log(RV_t)$. Para quebras na *média*, pode-se aplicar diretamente nos retornos.

2. O tamanho da janela “durante” afeta os resultados?

Sim. Por isso a análise de sensibilidade (testar $X \pm \Delta$) é essencial para validar as conclusões [Inoue et al., 2016].

3. Posso comparar modelos SV estimados em janelas diferentes com Bayes Factor?

Formalmente, Bayes Factors comparam modelos dados os *mesmos dados*. Para janelas diferentes, a prática padrão é comparar os intervalos de credibilidade dos parâmetros e reportar probabilidades posteriores de diferença [Kastner, 2016].

4. O que fazer se a janela “durante” tiver poucas observações?

Modelos SV via MCMC podem ser estimados com amostras pequenas, mas as posteriors serão largas (maior incerteza). Nesse caso, priors informativas (baseadas na literatura ou na janela pré-quebra) podem ajudar a estabilizar a estimação [Kastner, 2016].

5. É necessário apresentar testes frequentistas além do MCMC?

São recomendados como robustness checks (ARCH-LM, testes de distribuição), mas não obrigatórios se os diagnósticos bayesianos forem sólidos [Jiang et al., 2023, Shen et al., 2020].

Referências

- [Abdennadher and Hallara, 2018] Abdennadher, E. and Hallara, S. (2018). Structural breaks and stock market volatility in emerging countries. *International Journal of Business Research and Management*, pages 9–16.
- [Ahsan and Dufour, 2025] Ahsan, M. N. and Dufour, J. (2025). High-frequency instruments and identification-robust inference for stochastic volatility models. *Journal of Time Series Analysis*, 46.
- [Andreou and Ghysels, 2002] Andreou, E. and Ghysels, E. (2002). Detecting multiple breaks in financial market volatility dynamics. *Journal of Applied Econometrics*, 17:579–600.
- [Antoch et al., 2019] Antoch, J., Hanousek, J., Horvath, L., Huskova, M., and Wang, S. (2019). Structural breaks in panel data: Large number of panels and short length time series. *Econometric Reviews*, 38:828–855.
- [Aue and Horvath, 2013] Aue, A. and Horvath, L. (2013). Structural breaks in time series. *Journal of Time Series Analysis*, 34.
- [Bai and Perron, 2002] Bai, J. and Perron, P. (2002). Computation and analysis of multiple structural-change models. *Journal of Applied Econometrics*, 17:1–22.
- [Baiardi et al., 2020] Baiardi, C., Costabile, M., De Giovanni, D., Lamantia, F., Leccadito, A., Massabó, I., Menzietti, M., Pirra, M., Russo, E., and Staino, A. (2020). The dynamics of the s&p 500 under a crisis context: Insights from a three-regime switching model. *Risks*.
- [Bauwens et al., 2014] Bauwens, L., Backer, B. D., and Dufays, A. (2014). A bayesian method of change-point estimation with recurrent regimes: Application to garch models. *Journal of Empirical Finance*, 29:207–229.

- [Bormetti et al., 2019] Bormetti, G., Casarin, R., Corsi, F., and Livieri, G. (2019). A stochastic volatility model with realized measures for option pricing. *Journal of Business & Economic Statistics*, 38:856–871.
- [Chan, 2018] Chan, J. (2018). Specification tests for time-varying parameter models with stochastic volatility. *Econometric Reviews*, 37:807–823.
- [Chan, 2022] Chan, J. (2022). Comparing stochastic volatility specifications for large bayesian vars. *Journal of Econometrics*.
- [Chan and Eisenstat, 2018] Chan, J. C. C. and Eisenstat, E. (2018). Bayesian model comparison for time-varying parameter vars with stochastic volatility. *Journal of Applied Econometrics*, 33:509–532.
- [Chin et al., 2016] Chin, W., Lee, M. C., and Yap, G. (2016). Heterogeneous autoregressive model with structural break using nearest neighbor truncation volatility estimators for dax. *SpringerPlus*, 5.
- [Dufour and Valéry, 2009] Dufour, J.-M. and Valéry, P. (2009). Exact and asymptotic tests for possibly non-regular hypotheses on stochastic volatility models. *Journal of Econometrics*, 150:193–206.
- [Gaetano, 2018] Gaetano, D. D. (2018). Forecast combinations for structural breaks in volatility: Evidence from brics countries. *Journal of Risk and Financial Management*.
- [Ghezal et al., 2024] Ghezal, A., Balegh, M., and Zemmouri, I. (2024). Markov-switching threshold stochastic volatility models with regime changes. *AIMS Mathematics*.
- [Hasanov et al., 2024a] Hasanov, A., Brooks, R., Abrorov, S., and Burkhanov, A. (2024a). Structural breaks and garch models of exchange rate volatility: Re-examination and extension. *Journal of Applied Econometrics*.
- [Hasanov et al., 2024b] Hasanov, A., Burkhanov, A., Usmonov, B., Khajimuratov, N., and Khurramova, M. M. Q. (2024b). The role of sudden variance shifts in predicting volatility in bioenergy crop markets under structural breaks. *Energy*.
- [He and Lin, 2022] He, X. and Lin, S. (2022). A new nonlinear stochastic volatility model with regime switching stochastic mean reversion and its applications to option pricing. *Expert Systems with Applications*, 212:118742.
- [Inoue et al., 2016] Inoue, A., Jin, L. L., and Rossi, B. (2016). Rolling window selection for out-of-sample forecasting with time-varying parameters. *Journal of Econometrics*, 196:55–67.

- [Jia, 2025] Jia, R. (2025). Change-point detection in financial time series using the pelt algorithm: Simulation optimization and empirical analysis. In *Proceedings of the 2025 8th International Conference on Computer Information Science and Artificial Intelligence*.
- [Jiang et al., 2023] Jiang, Z., Mensi, W., and Yoon, S. (2023). Risks in major cryptocurrency markets: Modeling the dual long memory property and structural breaks. *Sustainability*.
- [Kashyap and Kashyap, 2020] Kashyap, S. and Kashyap, S. (2020). Dynamics of volatility spillovers with structural breaks in indian foreign exchange market. *International Journal of Business Innovation and Research*.
- [Kastner, 2016] Kastner, G. (2016). Dealing with stochastic volatility in time series using the r package stochvol. *Journal of Statistical Software*, 69:1–30.
- [Kokoszka et al., 2024] Kokoszka, P., Kutta, T., Mohammadi, N., Wang, H., and Wang, S. (2024). Detection of a structural break in intraday volatility pattern. *Stochastic Processes and their Applications*.
- [Lombera, 2024] Lombera, e. a. (2024). The dynamics of the s&p 500 under a crisis context: Insights from a three-regime switching model. *Risks*. Referenced in PDF snippets; full author list not fully visible.
- [Makatjane and Molefe, 2020] Makatjane, K. and Molefe, E. (2020). Predicting regime shifts in johannesburg stock exchange allshare index (jse-alsi): A markov-switching approach. *Eurasian Journal of Economics and Finance*, 8:95–103.
- [Ndako, 2025] Ndako, e. a. (2025). Global evidence on structural breaks across 16 countries, 1919–2020. Mentioned in PDF snippets; full bibliographic details not fully visible.
- [Omori et al., 2007] Omori, Y., Chib, S., Shephard, N., and Nakajima, J. (2007). Stochastic volatility with leverage: Fast and efficient likelihood inference. *Journal of Econometrics*, 140:425–449.
- [Pesaran and Timmermann, 1999] Pesaran, M. and Timmermann, A. (1999). Model instability and choice of observation window. Working paper / reference as listed in source PDF.
- [Pesaran and Timmermann, 2003] Pesaran, M. and Timmermann, A. G. (2003). Small sample properties of forecasts from autoregressive models under structural breaks. SSRN Electronic Journal.
- [Rohan and Ramanathan, 2012] Rohan, N. and Ramanathan, T. V. (2012). Asymmetric volatility models with structural breaks. *Communications in Statistics - Simulation and Computation*, 41:1519–1543.

- [Shapovalova, 2021] Shapovalova, Y. P. (2021). “exact” and approximate methods for bayesian inference: Stochastic volatility case study. *Entropy*, 23.
- [Shen et al., 2020] Shen, D., Urquhart, A., and Wang, P. (2020). Forecasting the volatility of bitcoin: The importance of jumps and structural breaks. *European Financial Management*.
- [Tamakoshi and Hamori, 2014] Tamakoshi, G. and Hamori, S. (2014). Greek sovereign bond index, volatility, and structural breaks. *Journal of Economics and Finance*, 38:687–697.
- [Vankov et al., 2019] Vankov, E., Guindani, M., and Ensor, K. (2019). Filtering and estimation for a class of stochastic volatility models with intractable likelihoods. *Bayesian Analysis*.